

The Instance Bottleneck: Why Near-Perfect Semantics Fails to Segment Individual Trees in ULS Data

Arturo Cantú Olivares¹, Diego Sebastian Cruz Cervantes¹,
Luis Fernando Maldonado¹, Jesús Gabriel Gudiño Lara¹, and Daniel Cantón
Enriquez¹

Universidad Autónoma de Querétaro (UAQ), Querétaro, México
dcruz54@alumnos.uaq.mx

Abstract. Automated individual tree segmentation (ITS) in high-density UAV laser scanning (ULS) point clouds is critical for scalable forest inventories, yet it remains unclear whether semantic preprocessing or the instance segmentation step is the main performance bottleneck. We present a controlled factorial comparison (3×2 design) of three preprocessing strategies — no preprocessing, Random Forest (RF) on geometric features, and PointNet++ MSG — combined with two variants of a volumetric Watershed 3D segmenter (classic CHM seeding and a novel density-based seeding), calibrated independently per pipeline and evaluated on the FOR-instance V1 benchmark across five forest types. Despite near-perfect semantic quality (tree IoU > 0.97 for both classifiers), instance F1 peaks at 0.209, revealing that the instance segmenter — not the semantic preprocessor — is the dominant bottleneck. RF with geometric features outperforms PointNet++ MSG in all pipeline combinations without requiring a GPU, and density-based seeding consistently improves over CHM seeding (+47% for RF, +74% for PointNet++), particularly in dense uniform-height canopies where CHM is nearly flat.

Keywords: Individual Tree Segmentation · UAV laser scanning (ULS) · Semantic segmentation · Watershed 3D · Density seeding · Random Forest · PointNet++ · FOR-instance

1 Introducción

1.1 Motivación

Automated forest inventories at tree-individual level are essential for carbon stock estimation, biodiversity monitoring, and precision forestry. UAV laser scanning (ULS) provides point densities one to two orders of magnitude higher than conventional ALS ($\sim 7,000$ pts/m² vs. ~ 5 pts/m²), enabling characterization of individual trees including crowns, trunks, branches, and understory. However, automated Individual Tree Segmentation (ITS) in ULS data remains an open problem due to height model noise, crown-understory ambiguity, and structural variability across forest types.

ITS pipelines typically operate in two cascaded stages: a semantic classifier that isolates tree points from ground, understory and noise, followed by an instance segmenter that assigns each tree point to a unique tree identifier. Deep learning methods such as PointNet++ [2] have raised expectations for semantic quality, yet their practical advantage over classical Random Forest classifiers in the specific context of ITS preprocessing remains unclear. At the same time, 3D volumetric Watershed methods have evolved beyond the classical 2D CHM approach [9], enabling direct exploitation of vertical point density. Despite these advances, the relative impact of each stage on end-to-end performance has rarely been isolated experimentally [2, 5, 1], and no controlled study has systematically varied the preprocessor while keeping the instance segmenter identical across multiple forest types.

1.2 Contribuciones

Las contribuciones de este trabajo son: (1) una comparación factorial 3×2 de tres preprocesados semánticos (sin preprocesado, RF, PointNet++ MSG) $\times$ dos estrategias de seeding (CHM, densidad) sobre FOR-instance V1 [1], con calibración independiente por flujo; (2) evidencia de que el segmentador de instancias, no el preprocesado, es el cuello de botella dominante; (3) demostración de que RF sin GPU supera a PointNet++ en todas las combinaciones; y (4) una variante de seeding por densidad de copa que mejora consistentemente al CHM clásico en canopías de altura uniforme.

2 Trabajo Relacionado

2.1 Individual tree detection and instance segmentation

In conventional ALS (<10 pts/m²), the dominant ITS approach detects CHM local maxima and delineates crowns via 2D watershed [8, 7, 9]. These methods degrade in dense, multi-layered canopies where crowns overlap. ULS data ($\sim 10^3$ – 10^4 pts/m²) enables volumetric 3D approaches that separate adjacent trunks and understory via fill rather than horizontal projection [9], but few works isolate the contribution of semantic preprocessing from the instance segmenter. This gap motivates our controlled factorial design.

2.2 Semantic segmentation of forest point clouds

Classical methods use handcrafted geometric features with Random Forest [5] or SVM [11, 12], while deep learning methods (PointNet [3], PointNet++ [2]) learn features end-to-end. PointNet++ has shown promising ULS results with height-normalized features [15], but semantic classification is predominantly evaluated as a final task; its role as ITS preprocessing remains understudied.

2.3 Benchmarks

FOR-instance V1 [1] assembles ULS plots from five forest types across four continents with point-level semantic and instance annotations. FOR-instanceV2 [10] extends it; we evaluate on V1 for comparability. NeonTreeEvaluation [6] provides multi-modal data but is limited to North American ecosystems.

3 Dataset

3.1 FOR-instance

FOR-instance V1 [1] es un benchmark ULS con anotaciones semánticas e de instancias a nivel de punto. Utilizamos cinco de las seis colecciones (Tabla 1), excluyendo NIBIO2 por sobre-representar el bosque boreal noruego, lo que sesgaría las métricas agregadas. Las densidades varían entre 454 y 10 156 pts/m² (mediana por colección: RMIT 473, TUWIEN 1 406, CULS 2 510, SCION 3 064, NIBIO 7 246). La diversidad geográfica y estructural es clave: NIBIO representa el 50% del test (bosque boreal denso), mientras que RMIT y TUWIEN presentan estructuras de copa radicalmente diferentes.

Table 1: Colecciones del dataset FOR-instance V1 utilizadas en este trabajo.

Código	País	Tipo de bosque	Plots test	Árboles GT
NIBIO	Noruega	Boreal conífero (<i>P. abies</i>)	6	161
CULS	Rep. Checa	Templado conífero (<i>P. sylvestris</i>)	1	20
TUWIEN	Austria	Mixto deciduo aluvial	1	35
RMIT	Australia	Esclerófilo seco (eucaliptos)	1	64
SCION	Nueva Zelanda	Plantación conífera (<i>P. radiata</i>)	2	43
Total			11	323

3.2 Splits y reproducibilidad

Se utiliza el split oficial (70% dev / 30% test) con subdivisión interna train/val (80/20%) a nivel de plot con semilla fija, siguiendo [13, 14].

4 Metodología

4.1 Visión general del pipeline

Los flujos comparten una arquitectura de dos etapas: (1) preprocesado semántico y (2) segmentador Watershed 3D, variadas factorialmente en cinco flujos (Fig. 1). Los parámetros del segmentador se calibran independientemente por flujo mediante grid search sobre val (F1 de instancia, IoU 3D ≥ 0.5).




Fig. 1: Análisis factorial: el seeding por densidad (rojo) supera al CHM (azul) en todos los métodos (+47–74%), con mejora mayor que el cambio de preprocesado (+27%).

4.2 Flujo A — Sin preprocesado (baseline)

La nube completa (excluyendo clases $\{0, 3\}$) se pasa directamente al segmentador. Todos los flujos comparten el cálculo de HAG a partir de un DTM interpolado sobre puntos de suelo, truncada a $[0, 50]$ m.

4.3 Flujo B — Random Forest sobre features geométricas

Cada punto se representa mediante 27 features geométricas: 8 descriptores eigen-basados y 5 descriptores locales (HAG, verticalidad, rugosidad, rango vertical, intensidad normalizada), calculados a dos vecindades $k \in \{20, 50\}$, más densidad volumétrica local ($r = 0,5$ m) [11, 12]. Se impone un radio máximo de búsqueda de 5,0 m. El clasificador es un Random Forest ($n = 200$ árboles, balanceo por clase) entrenado con submuestreo de 12 000 pts/clase/plot.

4.4 Flujo C — PointNet++ MSG

Se emplea PointNet++ MSG [2] con cuatro módulos Set Abstraction y cuatro Feature Propagation [4]. La entrada son 5 dimensiones por punto ($XYZ + HAG_norm + intensidad$), garantizando equivalencia de información con el Flujo B [15]. La red se entrena durante 100 épocas con submuestreos de 8 192 puntos. En inferencia se realizan múltiples pasadas con promediado de probabilidades; los puntos residuales se etiquetan por interpolación KNN ($k = 3$).

4.5 Segmentador de instancias — Watershed 3D volumétrico

El segmentador opera sobre los puntos clasificados como árbol en HAG y sigue cuatro pasos: (1) voxelización 3D en (X, Y, HAG) ; (2) suavizado gaussiano 3D de la grilla de densidad; (3) detección de semillas; y (4) watershed volumétrico sobre la densidad suavizada invertida con máscara de vóxeles ocupados [9]. A diferencia del watershed 2D sobre CHM, el fill volumétrico separa correctamente troncos adyacentes y puntos de sotobosque.

Variante CHM (Flujos A, B, C). Las semillas se detectan sobre la envolvente superior del volumen (equivalente a un CHM derivado del propio grid 3D) mediante `peak_local_max`.

Variante Density (Flujos D, E). Se reemplaza el CHM por una superficie de densidad acumulada en una banda de `top_band_m` metros bajo el vóxel más alto de cada columna. Esta superficie refleja concentraciones locales de puntos incluso cuando el CHM es casi plano, como en bosques boreales densos de altura uniforme.

Calibración. Parámetros calibrados por grid search independiente por flujo (Tabla 2, Fig. 2).

Table 2: Parámetros óptimos del Watershed 3D por flujo (grid search sobre val, F1 inst. IoU 3D ≥ 0.5).

Parámetro	Espacio	A	B (RF)	C (PN++)	D (RF+Dens.)	E (PN+++Dens.)
voxel_size (m)	{0.1, 0.2, 0.3}	0.2	0.1	0.1	0.2	0.3
gaussian_sigma	{0.3, 0.5, 1.0}	0.3	0.3	1.0	0.5	0.3
min_crown_radius_m	{0.5, 1.0, 1.5, 2.0}	0.5	1.0	1.5	2.0	1.5
top_band_m	{2.0, 3.0, 5.0}	—	—	—	2.0	5.0
F1 val (medio)		0.272	0.371	0.377	0.467	0.450




Fig. 2: Paisaje del grid search para el Flujo D (RF + Density). Barras rojas: valor óptimo. El radio mínimo de copa (2.0 m) es el parámetro más determinante.

5 Protocolo de Evaluación

Semántica. Se reportan tree IoU ($TP/(TP + FP + FN)$), seg mIoU (promedio de IoU de ambas clases) y seg F1 binario (árbol/no-árbol) a nivel de punto.

Instancias. Las instancias predichas $\{P_i\}$ se emparejan con las GT $\{G_j\}$ mediante matching *greedy* por IoU 3D punto a punto con umbral $\tau = 0.5$, siguiendo [13, 14]:

$$\text{IoU}_{3D}(P_i, G_j) = \frac{|P_i \cap G_j|}{|P_i \cup G_j|} \quad (1)$$

Se computan precisión, recall, F1 y *coverage* (fracción de árboles GT con al menos una predicción con $\text{IoU}_{3D} \geq \tau$, sin matching único): la brecha Coverage – Recall indica fragmentación de copas. Reportar ambas tareas permite aislar en cuál etapa se concentra el error.

6 Resultados

6.1 Resultados agregados

La Tabla 3 presenta los resultados sobre el conjunto de test. El Flujo D (RF + Density) alcanza el mejor F1 de instancia (0.209), superando al Flujo B (RF + CHM, 0.142) en un 47% relativo y al baseline (0.112) en un 87%. El seeding por densidad mejora consistentemente ambos métodos: RF sube de 0.142 a 0.209 y PointNet++ de 0.082 a 0.143.

Ambos clasificadores logran tree IoU > 0.97 , pero esta calidad no se traduce en instancia (F1 máximo 0.209), evidenciando al segmentador como cuello de botella.

6.2 Resultados por sitio

La Fig. 3 muestra la clasificación semántica sobre CULS 2. La diferencia clave entre clasificadores no es el volumen de error ($< 1\%$) sino su distribución: RF

Table 3: Resultados agregados (test, IoU 3D ≥ 0.5 , promedio sobre 11 plots).

Flujo	Seeding	sem	mIoU	tree	IoU	sem	F1	inst	Prec	inst	Recall	inst	F1	Coverage
A — Sin preproc.	CHM	—	—	—	—	—	0.138	0.133	0.112	0.133				
B — Random Forest	CHM	0.985	0.990	0.996	0.394	0.110	0.142	0.110						
C — PointNet++ MSG	CHM	0.974	0.982	0.994	0.172	0.060	0.082	0.060						
D — Random Forest	Density	0.985	0.990	0.996	0.418	0.150	0.209	0.150						
E — PointNet++ MSG	Density	0.974	0.982	0.994	0.209	0.118	0.143	0.118						

produce FP de borde de copa, mientras que PointNet++ genera FP aislados en suelo que se convierten en semillas espúreas.




Fig. 3: Clasificación semántica sobre CULS 2. Verde: árbol correcto; rojo: FP; naranja: FN. RF concentra errores en bordes de copa; PointNet++ produce FP aislados en suelo.

La Fig. 4 muestra el F1 por sitio. Los patrones clave son: (i) CULS es el único sitio con $F1 > 0.5$, gracias a copas bien separadas; (ii) NIBIO (50% del test) es el caso más desafiante por su canopia densa y uniforme; (iii) el seeding por densidad mejora en todos los sitios, con mayor ganancia relativa en RMIT (RF: 0.061 $\rightarrow$ 0.213) y TUWIEN (RF: 0.000 $\rightarrow$ 0.136), donde el CHM es particularmente ineficaz.

6.3 Visualización de segmentación de instancias

Las Figs. 5 y 6 muestran vistas superiores de predicciones: CULS exhibe buena separación de copas mientras que NIBIO muestra sobre-fusión persistente.

6.4 Análisis factorial: preprocesado $\times$ seeding

El análisis factorial (Tabla 4, Fig. 7) confirma que el cambio de seeding (CHM $\rightarrow$ Density) produce una mejora mayor (+47–74%) que el cambio de preprocesado (baseline $\rightarrow$ RF, +27%), identificando al segmentador como cuello de botella




Fig. 4: F1 de instancia por tipo de bosque. El Flujo D (RF + Density, rojo) domina en todos los sitios excepto CULS (F1=0.811 con Flujo B).




Fig. 5: Vista superior en CULS 2. El Flujo D logra la mejor separación (F1=0.629); el CHM tiende a fusionar copas adyacentes.




Fig. 6: Vista superior en NIBIO 17 (boreal denso). Under-segmentation severo en todos los métodos; F1 máximo 0.256 con Flujo D.

Table 4: F1 de instancia (test) en el diseño factorial. Δ : mejora relativa del seeding Density sobre CHM.

Preprocesado	CHM Density	Δ
Sin preproc. (baseline)	0.112	—
Random Forest	0.142 0.209	+47%
PointNet++ MSG	0.082 0.143	+74%

dominante. La interacción entre ambos factores es relevante: la semántica más limpia de RF produce menos semillas espúreas, resultando en menor sobre-segmentación (Precision RF+Density: 0.418 vs. PN++Density: 0.209).




Fig. 7: Desacoplamiento semántico-instancia. Tree IoU > 0.97 para ambos clasificadores, pero F1 inst. difiere $2.5\times$ (RF vs. PN++ con CHM). El segmentador es el factor dominante.

6.5 Importancia de features — Random Forest

La HAG domina la clasificación RF con el 61.5% de la importancia Gini acumulada en sus dos escalas ($k = 50$: 0.325; $k = 20$: 0.290), confirmando que la altura sobre el suelo es el predictor primario de la separación árbol/no-árbol. La verticalidad (0.087) y la rugosidad (0.072) a escala gruesa aportan información geométrica complementaria.

7 Discusión

7.1 El segmentador como cuello de botella

La Fig. 8 ilustra cómo el Flujo D asigna correctamente puntos de tronco y ramas en CULS 2, mientras que la proyección 2D del CHM confundiría estos puntos. El fill volumétrico del Watershed 3D es la diferencia estructural decisiva.




Fig. 8: Perfil vertical (7m) en CULS Plot 2. El Flujo D (centro) separa correctamente los árboles usando fill volumétrico; PointNet++ + CHM (derecha) confunde troncos compartidos.

El hallazgo central (Fig. 7) es que la semántica casi perfecta (tree IoU > 0.97) no se traduce en calidad de instancia proporcional (F1 máximo 0.209). El factor limitante es la capacidad del Watershed 3D para generar semillas correctas y separar copas adyacentes. El análisis factorial confirma que la inversión más rentable en un pipeline ITS de dos etapas no está en mejorar la semántica — que RF ya supera ampliamente — sino en mejorar el segmentador de instancias. El efecto es dependiente del sitio: en CULS (copas separadas), RF+CHM alcanza F1=0.811 y el Density seeding no aporta mejora sustancial; en NIBIO, RMIT y TUWIEN, donde las copas se superponen, el CHM falla sistemáticamente y el Density seeding es necesario para obtener rendimiento no trivial.

7.2 RF vs. PointNet++: viabilidad sin GPU y generalización

RF supera a PointNet++ en todas las combinaciones de seeding. Esta ventaja no se explica por semántica superior (brecha en tree IoU < 1 pp), sino por mejor interacción con el segmentador: los errores de RF son falsos positivos de borde de copa, mientras que PointNet++ genera falsos positivos aislados en suelo que producen semillas espúreas. Además, RF se entrena e infiere en CPU (~16 min) sin requerir GPU.

PointNet++ muestra caída severa en RMIT y TUWIEN (F1=0.000 con CHM), debido a que su submuestreo global de 8192 puntos no captura adecuadamente sitios con densidades y morfologías muy diferentes a los datos de entrenamiento (dominados por NIBIO boreal). RF, al operar sobre features locales, generaliza mejor entre tipos de bosque diversos.

7.3 Limitaciones

El conjunto de test comprende 11 plots y 323 árboles GT, lo que introduce varianza en estimaciones por sitio (especialmente CULS con 20 árboles y TUWIEN con 35). PointNet++ se evalúa con una única configuración de hiperparámetros; una búsqueda exhaustiva podría mejorar su rendimiento. Las conclusiones sobre el cuello de botella son específicas al Watershed 3D volumétrico; otros segmentadores (ForAINet [13], SegmentAnyTree [14]) podrían mostrar una relación diferente. Los resultados son específicos a datos ULS (454–10 156 pts/m²); la transferencia a ALS convencional no está garantizada.

8 Conclusiones

Mediante un diseño factorial 3×2 sobre FOR-instance V1, demostramos que: (1) el segmentador de instancias, no el preprocesado semántico, es el cuello de botella principal del pipeline ITS; (2) Random Forest con features geométricas supera a PointNet++ MSG en todas las combinaciones evaluadas, sin requerir GPU; y (3) el seeding por densidad de copa mejora consistentemente al seeding CHM (+47% para RF, +74% para PointNet++), siendo especialmente efectivo en bosques densos de altura uniforme.

La combinación RF + Watershed 3D Density alcanza el mejor F1 de instancia (0.209 en test), estableciendo una línea base robusta y eficiente. La brecha entre calidad semántica y calidad de instancia sugiere que las mejoras más impactantes en ITS vendrán de segmentadores capaces de separar copas adyacentes en copias densas — mediante priors sobre geometría de copa, segmentadores end-to-end, o mejores estrategias de seeding. Trabajo futuro incluye comparación con ForAINet [13] y SegmentAnyTree [14], extensión a FOR-instanceV2 [10], y estrategias de seeding adaptativas que combinen CHM y densidad según la variabilidad local de altura. El código fuente y los scripts de reproducción están disponibles en <https://github.com/Cantuuuu/ITS-Pipeline-Comparison>.

References

1. Puliti, S., et al.: FOR-instance: a UAV laser scanning benchmark dataset for semantic and instance segmentation of individual trees. arXiv preprint arXiv:2309.01279 (2023). DOI: 10.5281/zenodo.8287792
2. Qi, C.R., Yi, L., Su, H., Guibas, L.J.: PointNet++: Deep hierarchical feature learning on point sets in a metric space. In: Advances in Neural Information Processing Systems (NeurIPS), pp. 5099–5108 (2017)
3. Qi, C.R., Su, H., Mo, K., Guibas, L.J.: PointNet: Deep learning on point sets for 3D classification and segmentation. In: IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 652–660 (2017)
4. Yan, X.: Pointnet_Pointnet2_pytorch: PyTorch implementation of PointNet and PointNet++. GitHub repository, https://github.com/yanx27/Pointnet_Pointnet2_pytorch (2019). Accedido 2026-04
5. Breiman, L.: Random Forests. Machine Learning **45**(1), 5–32 (2001)

6. Weinstein, B.G., Marconi, S., Bohlman, S., Zare, A., White, E.: A benchmark dataset for individual tree crown delineation in co-registered airborne RGB, LiDAR and hyperspectral imagery. *Methods in Ecology and Evolution* **12**(10), 1847–1856 (2021)
7. Silva, C.A., Hudak, A.T., Vierling, L.A., et al.: Imputation of individual longleaf pine (*Pinus palustris* Mill.) tree attributes from field and LiDAR data. *Canadian Journal of Remote Sensing* **42**(5), 554–573 (2016)
8. Popescu, S.C., Wynne, R.H., Nelson, R.F.: Estimating plot-level tree heights with lidar: local filtering with a canopy-height based variable window size. *Computers and Electronics in Agriculture* **37**(1–3), 71–95 (2002)
9. Dalponte, M., Coomes, D.A.: Tree-centric mapping of forest carbon density from airborne laser scanning and hyperspectral data. *Methods in Ecology and Evolution* **7**(10), 1236–1245 (2016)
10. Xiang, B., et al.: FOR-instanceV2: A large-scale benchmark for 3D forest point cloud instance segmentation. (2025)
11. Weinmann, M., Jutzi, B., Hinz, S., Mallet, C.: Semantic point cloud interpretation based on optimal neighborhoods, relevant features and efficient classifiers. *ISPRS Journal of Photogrammetry and Remote Sensing* **105**, 286–304 (2015)
12. Weinmann, M., Jutzi, B., Mallet, C., Weinmann, M.: Geometric features and their relevance for 3D point cloud classification. *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences* **IV-1/W1**, 157–164 (2017)
13. Henrich, J., et al.: ForAINet: Deep learning for forest point cloud semantic and instance segmentation. (2024)
14. Wielgosz, M., et al.: SegmentAnyTree: A sensor and platform agnostic deep learning model for tree segmentation using laser scanning data. (2024)
15. Wang, D., et al.: Semantic segmentation of forest point clouds: Combining deep learning with height-normalized intensity features. *Remote Sensing* **15**(8) (2023)